



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

*Arquitectura Vision-To-Text: Primer
acercamiento*

Fusión de Visión Computacional y Modelos de Lenguaje para la
Transferencia de Conocimiento en Agricultura de Precisión

Juan Ricardo Albarracín Barbosa
Luis Ángel Oporto Añacato
David Alexis García Espinosa

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales
Mtra. Verónica Sandra Guzmán de Valle

Dr. Gerardo Jesús Camacho González

PROYECTO INTEGRADOR
25 DE MAYO DE 2025

1. Introducción

El primer acercamiento a la implementación de una arquitectura de Vision-To-Text, se realiza mediante la combinación del encoder visual adaptado del modelo TSViT (Temporal-Spatial Vision Transformer) con un decoder basado en una arquitectura LLM (Large Language Model), como GPT-2 y Llama-3.2-1B-Instruct, modelos autoregresivos de lenguaje natural. El objetivo principal es probar la posibilidad de generar descripciones textuales a partir de secuencias temporales de imágenes satelitales, modelando tanto la dimensión espacial como la evolución temporal de los datos.

2. Dataset

2.1. Mask-To-Text

Para entrenar la arquitectura Vision-To-Text, fue necesario contar con un conjunto de datos que contuviera pares de entrada visual (secuencia de imágenes) y salida textual (descripción o caption). Dado que originalmente solo se disponía de máscaras de segmentación categorizadas por tipo de cultivo [1], se desarrolló una función Mask-To-Text para generar automáticamente descripciones a partir de dichas máscaras.

Esta función toma una máscara de segmentación (una matriz con etiquetas por píxel) proveniente de los labels de PASTIS24 [1] y un diccionario de nombres de clases, y produce un texto descriptivo que resume las áreas ocupadas por cada tipo de cultivo presente en la imagen. Un ejemplo del caption generado para una secuencia temporal de imágenes de cultivos es:

“A crop of can be identified in the image meadow spanning approximately 29700 m², winter barley representing an area of around 12500 m², which accounts for a considerable fraction of the total agricultural area: 57600 m².”

Cabe destacar que, actualmente se está trabajando en el cálculo y análisis del Índice de Vegetación de Diferencia Normalizada NDVI para enriquecer las descripciones usadas para entrenar y por ende, mejorar las descripciones generadas.

3. Vision-To-Text

La arquitectura Vision-To-Text se inspira en los avances recientes en el campo del image captioning [2], una tarea que consiste en generar descripciones en lenguaje natural a partir de imágenes. Este enfoque combina modelos de visión por computadora con modelos generativos de lenguaje, estableciendo una arquitectura encoder-decoder en la que una red de visión extrae representaciones visuales que luego son decodificadas por un modelo de lenguaje.

3.1. Encoder Visual

El encoder se basa en la arquitectura de TSViT [3], diseñada originalmente para procesar imágenes satelitales multitemporales de cultivos. Este encoder está compuesto por dos bloques Transformer:

- **Bloque Temporal:** Permite capturar la evolución dinámica de las observaciones en el tiempo T para cada ubicación espacial. La atención se aplica sobre las características visuales a través de los diferentes pasos temporales.
- **Bloque Espacial:** Posterior al procesamiento temporal, este bloque aplica atención sobre las posiciones espaciales (por ejemplo, patches o regiones de la imagen) en un instante dado, lo que permite integrar relaciones espaciales complejas entre las distintas partes de cada imagen.

Ambas dimensiones temporal y espacial son fundamentales para representar fenómenos agrícolas o ambientales que varían en el tiempo y el espacio, como la fenología de cultivos.

La salida final del encoder es un conjunto de embeddings que representan la secuencia multitemporal completa. De estos, se utiliza una representación global (token CLS) como resumen visual de entrada al decoder textual.

3.2. Proyección Visual

En una arquitectura Vision-to-Text, es necesaria la creación de un módulo de proyección visual que actúa como un “puente” o “adaptador” entre el encoder visual y el decoder textual. Este componente traduce los embeddings generados por el backbone del encoder al espacio semántico

esperado por el modelo de lenguaje, no solo proyectándolos o ajustando sus dimensiones, sino que también alineando semánticamente los dos espacios latentes que fueron entrenados en un principio, con objetivos distintos: uno visual y otro lingüístico.

3.3. Decoder Textual

Los decoders probados son instancias de modelos LLM pre-entrenados, tanto GPT-2 [4] como Llama-3.2-1B-Instruct, son Transformers autoregresivos ampliamente utilizados para tareas de generación de texto. Ambos modelos están entrenados para predecir/responder la siguiente palabra (token) dado un contexto anterior.

El objetivo principal del Decoder en Vision To Text es predecir el siguiente token en la secuencia, condicionándose en la información previamente generada y en las representaciones visuales proyectadas tomando las representaciones como contexto inicial y produciendo la descripción textual correspondiente a la imagen o secuencia visual. Durante el entrenamiento, aprende a mapear las características visuales codificadas a texto puro.

3.4. Proceso General Vision-To-Text

A continuación, se detalla el flujo de información en la primera aproximación a la arquitectura Vision-To-Text descrita anteriormente:

- **Entrada:**

- Secuencia de imágenes con forma $[B, T, C, H, W]$, donde B es el tamaño del lote, T es la cantidad de imágenes en la secuencia, C el número de canales, y H, W la altura y ancho de cada imagen.
- Secuencia de tokens de texto con forma $[B, T_{text}]$, donde T_{text} es la longitud de la secuencia textual.

- **Congelación del encoder visual:** Para preservar el conocimiento previamente aprendido del encoder visual, se congelan sus parámetros, evitando que se actualicen durante el entrenamiento. Esto permite entrenar únicamente el decodificador textual y la capa de proyección.

- **Extracción de embeddings visuales:** El encoder procesa la secuencia de imágenes y genera embeddings visuales con forma $[B, T, D_{enc}]$, donde D_{enc} es la dimensión de los embeddings generados por el encoder.

- **Proyección del embedding visual representativo:** Se extrae el primer vector de embeddings temporales $[B, D_{enc}]$ que es el CLS y representa globalmente la información visual. Este vector se proyecta linealmente a la dimensión de embeddings del decodificador, D_{dec} (768 para GPT-2), obteniendo un tensor de forma $[B, 1, D_{dec}]$.
- **Embeddings textuales:** Los tokens de entrada se convierten en embeddings con forma $[B, T_{text}, D_{dec}]$, utilizando la capa de embeddings del decodificador.
- **Concatenación de embeddings:** Se concatenan los embeddings proyectados de la imagen y los embeddings de texto a lo largo de la dimensión temporal, formando un tensor combinado con forma $[B, 1 + T_{text}, D_{dec}]$.
- **Máscara de atención combinada:** Se crea una máscara de atención que incluye un token adicional para la representación visual, con forma $[B, 1 + T_{text}]$.
- **Ajuste de etiquetas para el entrenamiento:** Como la entrada al decodificador comienza con un vector que representa visualmente la secuencia de imágenes, se evita calcular la pérdida sobre esta posición. Para ello, se modifica la secuencia de etiquetas estableciendo un valor especial que indica a la función de pérdida que debe ser ignorado. De esta manera, solo se penalizan las predicciones correspondientes a los tokens textuales reales., manteniendo la forma $[B, 1 + T_{text}]$.
- **Decodificación:** Finalmente, los embeddings concatenados junto con la máscara de atención y etiquetas son pasados al decodificador para generar la predicción textual y calcular la pérdida.

Este proceso permite que el modelo integre de forma efectiva la información visual y textual, condicionando la generación de texto a partir de las imágenes procesadas, favoreciendo descripciones precisas y contextualizadas.

Nota: Actualmente se está explorando el uso del modelo LLaMA-3.2-Vision-11B como alternativa al decodificador GPT-2/Llama-3.2-1B-Instruct, para lo cual se requiere reemplazar el encoder visual de LLaMA-3.2-Vision-11B por el encoder TSViT, con el objetivo de mejorar la calidad y coherencia de las descripciones generadas a partir de las representaciones visuales de

las imágenes satelitales, y en general, mejorar el desempeño del pipeline de generación de descripciones de cultivos.

Anexos

El código fuente, incluyendo notebooks y scripts de preprocesamiento, definición del modelo y entrenamiento, se encuentra disponible en el siguiente repositorio de GitHub:

- **Repositorio:** `github.com/juanrtato/crop-image-deepanalysis`
- **Entrenamiento GPT-2:**
`notebooks/vtt_model_exp.ipynb`
- **Entrenamiento Llama-3.2-1B-Instruct:**
`notebooks/tsvit&llama_model_exp.ipynb`
- **Preprocesamiento de datos:**
`notebooks/mask2text.ipynb`
- **Definición del modelo Vision-to-Text con GPT-2:**
`scripts/visiontotext/visiontotextmodel.py`
- **Definición del modelo Vision-to-Text con Llama-3.2-1B-Instruct:**
`scripts/visiontotext/llamavlm.py`

Referencias

- [1] V. Sainte Fare Garnot y L. Landrieu, «Panoptic Segmentation of Satellite Image Time Series with Convolutional Temporal Attention Networks,» *ICCV*, 2021.
- [2] O. Vinyals, A. Toshev, S. Bengio y D. Erhan, «Show and tell: A neural image caption generator,» en *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, págs. 3156-3164.
- [3] M. Tarasiou, E. Chavez y S. Zafeiriou, «Vits for sits: Vision transformers for satellite image time series,» en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, págs. 10 418-10 428.

- [4] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever et al., «Language models are unsupervised multitask learners,» *OpenAI blog*, vol. 1, n.º 8, pág. 9, 2019.