



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

*Estimación de Periodos de Siembra y
Cosecha Basada en NDVI & Reporte de
Avance Semanal – Proyecto de Análisis de
Cultivos con Transformers y LLMs*

Fusión de Visión Computacional y Modelos de Lenguaje para la
Transferencia de Conocimiento en Agricultura de Precisión

Juan Ricardo Albarracín Barbosa
Luis Ángel Oporto Añacato
David Alexis García Espinosa

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales
Mtra. Verónica Sandra Guzmán de Valle

Dr. Gerardo Jesús Camacho González

PROYECTO INTEGRADOR
1 DE JUNIO DE 2025

0.1. Estimación de Periodos de Siembra y Cosecha Basada en NDVI

Para mejorar la descripción semántica de los cultivos y generar captions más informativas, se requiere estimar eventos clave como los periodos de siembra y cosecha. Esto se realiza analizando la evolución temporal del índice de vegetación NDVI (Normalized Difference Vegetation Index), el cual es un buen indicador del vigor y cobertura vegetal.

1. Limpieza y depuración de datos

Antes de la estimación, se eliminan observaciones no confiables o ruidosas, como aquellas:

- Con valores de NDVI promedio muy bajos (indicando suelo desnudo o datos ausentes).
- Afectadas por nubes, detectadas mediante umbrales espectrales.

2. Detección de nubes

Dado que las nubes afectan negativamente la calidad de las observaciones satelitales, se aplica un método simple de umbral para identificar y descartar observaciones contaminadas. La detección se basa en tres bandas espectrales: azul, SWIR1 y SWIR2. Cuando los valores reflejados en estas bandas exceden ciertos umbrales, se considera que hay presencia de nubes. Se dice que si una observación tiene nubes es porque:

$$\text{cloud}(t) = \begin{cases} 1, & \text{si } \text{Blue}_t > \theta_B \wedge \text{SWIR1}_t > \theta_S \wedge \text{SWIR2}_t > \theta_S \\ 1, & \text{si } \overline{\text{NDVI}}_t < \theta_{\text{NDVI}} \end{cases}$$

donde:

- $\theta_B = 0,2$ es el umbral para la banda azul,
- $\theta_S = 0,15$ es el umbral para las bandas SWIR1 y SWIR2,
- $\theta_{\text{NDVI}} = 0,1$ es el umbral de NDVI promedio por imagen.

3. Estimación de periodos de siembra y cosecha

Tras la limpieza, se analiza la serie temporal de NDVI para detectar cambios significativos. Se calcula la primera diferencia temporal del NDVI:

$$\Delta\text{NDVI}_t = \text{NDVI}_{t+1} - \text{NDVI}_t$$

Los eventos se definen como:

- **Siembra** cuando:

$$\Delta\text{NDVI}_t > \delta_{\text{start}}$$

- **Cosecha** cuando:

$$\Delta\text{NDVI}_t < -\delta_{\text{end}}$$

donde δ_{start} y δ_{end} son umbrales definidos empíricamente (por ejemplo, 0.05). Solo se consideran periodos que cumplen una duración mínima y se priorizan aquellos con mayor NDVI promedio, lo que suele reflejar un desarrollo vegetativo saludable.

Finalmente, se fusionan periodos consecutivos o solapados para evitar duplicaciones, y se manejan casos en los que se detecta una cosecha temprana sin una siembra visible. Esto contribuye a construir descripciones más detalladas y precisas de las dinámicas agrícolas a partir de datos satelitales.

0.2. Generación de descripciones semánticas

Una vez identificadas las áreas cultivadas y los periodos de actividad agrícola mediante NDVI, se procede a la generación de descripciones textuales que resumen de forma comprensible y detallada la composición del paisaje agrícola y la dinámica temporal de los cultivos. Estas descripciones se estructuran en dos bloques:

1. **Descripción espacial:** Se informa la presencia y extensión aproximada de cada cultivo detectado.
2. **Descripción temporal:** Se indican los periodos estimados de siembra y cosecha para cada tipo de cultivo.

Este proceso emplea plantillas de texto dinámicas que permiten integrar las variables relevantes (tipo de cultivo, área estimada, fechas de siembra y cosecha) de forma coherente y fluida. El resultado final son descripciones útiles tanto para análisis humano como para sistemas de documentación automatizada o generación de reportes.




Figura 1. Secuencia temporal de imágenes.

Ejemplo de caption generado para entrenamiento:

The image highlights the crop of Meadow occupying around 20800 m², Corn covering an area close to 24800 m², Potatoes occupying around 11100 m², which constitutes an important part of the agricultural area in the region.

Considering the crop seasonal phases, Meadow appears to have been planted in T=5 and harvested approximately in T=17. Furthermore, the life cycle of Corn spanned from around T=5 to about T=36. Also, the observed agricultural timeline for Potatoes suggests planting in T=12 and harvesting in T=18.




Figura 2. Máscara de segmentación.

Este tipo de salida permite vincular información visual con datos derivados del análisis temporal, mejorando la calidad semántica y la utilidad de los captions para el entrenamiento de la LLM.

Reporte de Avance Semanal – Proyecto de Análisis de Cultivos con Transformers y LLMs

En seguimiento a los objetivos planteados para el proyecto de análisis de cultivos, que integra el uso de transformers y modelos de lenguaje de gran escala (LLMs), se reportan los avances alcanzados durante la presente semana. En primera instancia, se logró integrar exitosamente un Visual Transformer con el modelo GPT-2.0, permitiendo generar descripciones textuales a partir de las características extraídas de las imágenes de cultivos. Esta conexión habilita un puente efectivo entre las representaciones visuales y el procesamiento textual, facilitando interpretaciones automatizadas que enriquecen el análisis de los datos agrícolas. Adicionalmente, se realizó un análisis temporal extendido del índice NDVI (Normalized Difference Vegetation Index), con-

templando la evolución de esta métrica a lo largo del tiempo. Este enfoque temporal contribuye a una evaluación dinámica y contextualizada de los cultivos, mejorando la detección de cambios y tendencias en el estado vegetativo mediante la integración de la serie temporal en el proceso analítico.

Paralelamente, se emprendió la extensión del código base de GPT-2.0 para adaptarlo a modelos alternativos, como LLama 3.2, y se está en proceso de evaluación para conectar los resultados con el modelo Qwen. Aunque LLama 3.2 muestra un desempeño aún limitado en el contexto del proyecto, ya se dispone de una comparativa preliminar entre tres modelos distintos que emplean arquitectura transformer, lo cual brinda un marco para futuras decisiones técnicas. Asimismo, se exploraron experimentos con fine-tuning utilizando la plataforma LLM Studio de H2O, en particular con modelos pequeños como Danube. Si bien los resultados en la generación de mensajes fueron adecuados, la integración de estos modelos en pipelines más complejos se encontró insuficiente para cubrir los requerimientos profundos del proyecto, lo que sugiere la necesidad de enfoques más robustos para el ajuste fino y la integración en producción.

Para revisar con mayor detalle el trabajo realizado en la integración y experimentación con el modelo LLama 3.2, se remite a la documentación y los notebooks desarrollados disponibles en el repositorio público en GitHub. En particular, el análisis completo y las pruebas con series temporales de imágenes satelitales pueden consultarse en la siguiente dirección: Código LLama 3.2 + ViTs, donde se presenta el código fuente, resultados preliminares y las metodologías aplicadas para esta etapa del proyecto.

En el marco de la evolución técnica del proyecto, se ha comenzado a planificar y ejecutar la migración del modelo LLaMA hacia Qwen, con el fin de potenciar la integración y capacidad multimodal del sistema basado en transformers y LLMs. En este proceso, se contemplaron diversos aspectos fundamentales, entre ellos el acceso y compatibilidad de pesos para Qwen, el cual es desarrollado por Alibaba y cuenta con versiones públicas accesibles en repositorios como HuggingFace. Se revisaron aspectos legales, técnicos y de compatibilidad con frameworks populares como PyTorch y Transformers de HuggingFace, asegurando una transición fluida. En cuanto al soporte multimodal, aunque algunas versiones recientes de Qwen integran capacidades nativas para procesar texto e imagen, la compatibilidad directa con el Visual Transformer especializado en series temporales satelitales (TSViT) no es inmediata. Por ello, se consideraron estrategias para adaptar la salida de

TSViT a formatos que Qwen pueda consumir o, en su defecto, emplear el módulo visual propio de Qwen, con miras a mantener la capacidad de procesamiento de datos espaciales y temporales.

Además, se analizó el uso de técnicas de cuantización para la carga eficiente del modelo, incluyendo formatos de 4 bits, que permiten optimizar el consumo de memoria y ajustar el despliegue a las capacidades del hardware disponible, replicando prácticas utilizadas previamente con LLaMA. Para garantizar la continuidad del pipeline, se contemplaron los ajustes necesarios en el código fuente, incluyendo la sustitución de llamadas específicas de LLaMA por equivalentes en Qwen, así como la actualización de importaciones, carga de modelos, tokenizadores y métodos de generación, con el objetivo de mantener la funcionalidad y estabilidad durante la inferencia y el entrenamiento.

En cuanto al análisis comparativo entre LLaMA y Qwen, se destaca que ambos modelos representan arquitecturas Transformer decoder-only, pero con diferencias relevantes en diseño, ecosistema y soporte multimodal. LLaMA, ampliamente adoptado en la comunidad de investigación, ofrece flexibilidad y eficiencia con versiones que van desde 7 mil millones hasta 65 mil millones de parámetros, y soporta integración con módulos visuales personalizados, como ViT o TSViT. Por otro lado, Qwen, desarrollado por Alibaba, presenta soporte multimodal nativo con versiones conocidas de 7 y 14 mil millones de parámetros, y una arquitectura modular que facilita la integración directa de visión y lenguaje, aunque con un diseño visual diferente al empleado en LLaMA. En términos de ecosistema, LLaMA posee mayor madurez, documentación y comunidad activa, mientras que Qwen está en una fase de crecimiento, con herramientas en desarrollo y menor soporte consolidado.

La integración multimodal en LLaMA suele requerir adaptaciones externas y módulos visuales personalizados, lo que brinda flexibilidad para dominios específicos, como imágenes satelitales, mientras que Qwen ofrece soporte multimodal integrado, reduciendo la necesidad de modificaciones, aunque con posibles limitaciones para reutilizar módulos visuales especializados sin reentrenamiento. Desde la perspectiva de eficiencia computacional, LLaMA cuenta con amplias técnicas de cuantización y optimizaciones, apoyadas por una comunidad dinámica, mientras que Qwen está en desarrollo para optimizaciones similares. Finalmente, el fine-tuning en LLaMA está bien soportado con técnicas modernas, en contraste con Qwen, que aún se encuentra en etapa inicial para ajustes específicos.

En síntesis, la elección entre LLaMA y Qwen depende de las características del proyecto, considerando la especificidad del dominio visual, el soporte disponible, y los requerimientos de multimodalidad y despliegue. LLaMA ofrece mayor flexibilidad y madurez, especialmente para proyectos con módulos visuales personalizados, mientras que Qwen aporta una solución multimodal integrada y modular con potencial de rápida evolución. La evaluación cuidadosa de estos factores permitirá optimizar el desempeño y la eficiencia del sistema para el análisis avanzado de cultivos y monitoreo ambiental.

Arquitectura y Diseño Técnico del Modelo Qwen

El modelo Qwen se basa en una versión modificada de la arquitectura Transformer, tomando como referencia principal el modelo LLaMA (Touvron et al., 2023a), reconocido como uno de los mejores modelos de lenguaje abierto a gran escala. Este diseño incorpora diversas modificaciones arquitectónicas y de optimización para mejorar el desempeño. Se implementa en varias escalas, con configuraciones que incluyen parámetros desde 1.8 mil millones hasta 14 mil millones, variando el tamaño de la representación oculta, el número de cabezas de atención, capas y tokens entrenados, ajustados para equilibrar capacidad y eficiencia.

Qwen utiliza un esquema de *embedding* no atado, donde las matrices de pesos para la representación de entrada y la proyección de salida no comparten parámetros, priorizando el rendimiento a costa de un mayor uso de memoria. Para la información posicional, adopta el método Rotary Positional Embedding (RoPE), que introduce una codificación rotatoria que mejora la generalización en secuencias largas. Esta codificación utiliza frecuencias inversas calculadas con precisión en formato FP32, asegurando exactitud y estabilidad. En cuanto al manejo de sesgos, la mayoría de las capas eliminan los términos de sesgo para simplificar la arquitectura, salvo la capa de atención (QKV), que mantiene sesgos para potenciar la capacidad de extrapolación.

En términos de normalización, Qwen emplea pre-normalización (Pre-Norm) para mayor estabilidad durante el entrenamiento, sustituyendo la normalización tradicional por capas (Layer Normalization) con RMSNorm, una técnica que mejora la eficiencia computacional sin sacrificar rendimiento. La función de activación utilizada es SwiGLU, que combina Swish con unidades

lineales con compuerta, demostrando superioridad sobre funciones clásicas como GeLU. Finalmente, la arquitectura del feed-forward network (FFN) se ajusta a aproximadamente 2.67 veces el tamaño oculto, buscando un balance entre capacidad y eficiencia, en contraste con el factor 4 tradicional.

En conjunto, el diseño de Qwen representa una evolución refinada de la arquitectura Transformer para grandes modelos de lenguaje, con innovaciones en embeddings, codificación posicional, normalización, activaciones y arquitectura interna, enfocadas en optimizar rendimiento, eficiencia y capacidad de generalización, alineándose con las mejores prácticas actuales en LLMs. Este modelo apunta a soportar aplicaciones complejas y de alta demanda, como análisis multimodal en agricultura de precisión y monitoreo ambiental.

Descripción Formal de la Interconexión Multimodal en Qwen para Análisis de Imágenes Satelitales

El modelo Qwen extiende su capacidad para procesar información multimodal mediante la combinación de datos textuales y visuales procedentes de series temporales de imágenes satelitales. Esta arquitectura consta de módulos interconectados que permiten el procesamiento independiente y posterior fusión de modalidades. Por un lado, los tokens textuales se transforman mediante una capa de embedding con pesos no atados, incorporando información posicional con Rotary Positional Embedding (RoPE) en precisión FP32 para modelar adecuadamente las dependencias secuenciales.

Por otro lado, las imágenes satelitales se procesan a través de un Visual Transformer especializado, que extrae características espaciales y temporales, generando embeddings visuales compatibles con el espacio latente textual. Las representaciones resultantes de ambos procesos se integran en un bloque de fusión multimodal, que puede implementarse mediante concatenación simple o mediante mecanismos de atención cruzada, permitiendo interacciones contextuales avanzadas entre texto e imagen. Esta fusión genera una representación conjunta que encapsula la semántica textual y la información dinámica visual, crucial para tareas de análisis agrícola y ambiental.

Finalmente, esta representación multimodal ingresa al Transformer principal de Qwen, que incorpora técnicas avanzadas de pre-normalización con

RMSNorm, atención con sesgos en QKV para mejorar la extrapolación, función de activación SwiGLU, y una red feed-forward ajustada para balancear capacidad y eficiencia. La salida pasa por una capa de proyección no atada que genera tokens de salida o predicciones. Este esquema modular y optimizado permite al modelo explotar de manera eficiente y precisa las secuencias textuales y la compleja información espacial-temporal de imágenes satelitales, habilitando aplicaciones avanzadas en agricultura de precisión y monitoreo ambiental.




Figura 3. Arquitectura básica del Transformer con embeddings de entrada y proyección de salida no atados (untied). Se emplea pre-normalización con RMSNorm, atención con sesgo en QKV, activación SwiGLU y codificación posicional RoPE en precisión FP32 para mejorar estabilidad y desempeño.




Figura 4. Arquitectura multimodal que integra un pipeline textual y un Visual Transformer para imágenes satelitales en serie de tiempo. Las representaciones textuales y visuales se fusionan mediante concatenación o atención cruzada antes de ser procesadas por un Transformer principal con modificaciones específicas de Qwen.