



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

Conclusiones Clave

Fusión de Visión Computacional y Modelos de Lenguaje para la
Transferencia de Conocimiento en Agricultura de Precisión

Juan Ricardo Albarracín Barbosa
Luis Ángel Oporto Añacato
David Alexis García Espinosa

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales
Mtra. Verónica Sandra Guzmán de Valle

Dr. Gerardo Jesús Camacho González

PROYECTO INTEGRADOR

08 DE JUNIO DE 2025

1. Introducción

A lo largo del desarrollo del *Proyecto Integrador*, se ha logrado generar los descriptores adecuados de los cultivos, acorde a la fuente de datos elegida (*PASTIS*), estos descriptores incluyen, la identificación y clasificación por tipo de cultivo, estimación de la superficie y cantidad cultivada, así como la determinación de los periodos de siembra y cosecha, todo a partir de las series de tiempo de imágenes satelitales y el tratamiento adecuado de los canales disponibles; de esta manera se ha generado descriptores detallados y convenientemente humanizados, para ser usados en el proceso de entrenamiento de la Arquitectura TSViT-LLM propuesta.

La Arquitectura propuesta, incluye el uso del *encoder* de un modelo TSViT (*Time Series Vision Transformer*) pre-entrenado, ensamblado a un modelo LLM pre-entrenado a través de un *Projector Multimodal* o a través de capas *Cross Attention*, de tal manera que se aproveche el conocimiento de cultivos del LLM y el poder de identificación de cultivos del TSViT para imágenes satelitales; de esta manera obtener un modelo *multimodal* para imágenes satelitales en series de tiempo, que permita generar descriptores detallados que no solamente clasifiquen los cultivos sino puedan determinar la superficie y cantidad cultivada así como pueda estimar el periodo de siembra y la cosecha proyecta, además de obtener información adicional del tipo de cultivo aprovechando el conocimiento del LLM.

Luego de la experimentación con diferentes arquitecturas LLM, el uso del modelo multimodal *Llama 3.2 11B Vision*, muestran los mejores resultados. Para la construcción del modelo *TSViT-Llama 3.2* se reemplazó el modelo de visión de *Llama 3.2 11B Vision*, por el TSViT, logrando su integración a través de un *Projector Multimodal* conectado a cada una de los 8 capas *Cross Attention* del modelo LLM de Llama. Para el entrenamiento se consideró como parámetros entrenables tanto el *Projector Multimodal*, como cada una de las 8 capas *Cross Attention*.

Dado los resultados obtenidos, resulta factible la implementación del modelo multimodal propuesto, de esta forma se propone además, los requerimientos para su operacionalización y consumo, a través de un entorno de producción que se ajuste a los posibles requerimiento de los usuarios en el futuro.

2. Captioning Dataset

2.1. "Humanización" de fechas para descripciones textuales

Para generar mejores descripciones (captions) de los cultivos, a partir de información de siembra y cosecha, se implementó una estrategia de humanización de fechas. En lugar de usar las fechas estrictamente formateadas del dataset original (por ejemplo, 2019-03-15), se tradujeron a expresiones más naturales como *early March 2019*, *mid-April 2019*, o *October 20, 2019*:

- Se definieron tres grupos de patrones para representar tiempos aproximados: **inicio**, **mitad** y **fin** del mes.
- También, se definió un formato de fechas exactas, con día, mes y año: *"March 19, 2019"*.
- En caso de ausencia de fecha, o de la no identificación de periodos siembra-cosecha, se generaron frases como *"by an unknown date"* o *"no planting period was detected for the first planting period of the crop {crop}"* para mantener coherencia gramatical.

Esta humanización permitió utilizar plantillas lingüísticas más naturales, por ejemplo:

Regarding the planting and harvesting times, the crop {crop} was sown around {plant_time} and likely harvested in {harvest_time}."

Estas plantillas fueron rellenas de forma aleatoria y dinámicamente con las fechas humanizadas, generando textos fluidos y fáciles de interpretar.

Este proceso de humanización es crucial para nutrir el dataset de captions que será usado en la etapa de entrenamiento y evaluación de modelos LLM. Al convertir datos crudos a texto fluido y semánticamente significativo, se mejora la calidad del conjunto de datos y se facilita el aprendizaje de relaciones entre componentes espaciales, temporales y semánticos.

Nota: Dado que las muestras del dataset PASTIS fueron obtenidas entre los años 2018 y 2019, se está evaluando la posibilidad omitir las fechas exactas y el año en las fechas generadas (*e.g. mid-March* en lugar de *March 20, 2019* o *early March* en lugar de *early March 2019*). Esto con el fin de reducir el

riesgo de sesgo por parte del modelo LLM hacia años y fechas específicas, buscando fomentar que el modelo aprenda patrones estacionales generales, independientemente del año y fecha del calendario.

Ejemplos de descripciones generadas

Ejemplo 1:




Figura 1. Ejemplo 1: Máscara de segmentación.

A cultivated area with Soft winter wheat can be observed with an estimated surface of 24,700 m², Grapevine spanning approximately 9,700 m² which represents a significant portion of the total cultivated land (approximately 57,600 m²).

Now, let's examine the planting and harvesting periods, the crop Soft winter wheat likely experienced its growth period between about the midpoint of October 2018 and on April 15, 2019. Furthermore, the life cycle of Grapevine spanned from on October 12, 2018 to about in the last days of July 2019.




Figura 2. Ejemplo 1: Evolución temporal del cultivo.

Ejemplo 2:




Figura 3. Ejemplo 2: Máscara de segmentación.

The image shows a cultivated area of Meadow. A crop of Meadow can be identified in the image covering about 27,700 m², which covers a notable fraction of the total arable land (approximately 57,600 m²).

Looking into the sowing and reaping periods, the observed agricultural timeline for Meadow suggests planting in the middle of September 2018 and harvesting on July 17, 2019.




Figura 4. Ejemplo 2: Evolución temporal del cultivo.

La Arquitectura propuesta, incluye el uso del *encoder* de un modelo TS-ViT (*Time Series Vision Transformer*) pre-entrenado, ensamblado a un modelo LLM pre-entrenado a través de un *Projector Multimodal* o a través de capas *Cross Attention*, de tal manera que se aproveche el conocimiento de cultivos del LLM y el poder de identificación de cultivos del TSViT para imágenes satelitales; de esta manera obtener un modelo *multimodal* para imágenes satelitales en series de tiempo, que permita generar descriptores detallados que no solamente clasifiquen los cultivos sino puedan determinar la superficie y cantidad cultivada así como pueda estimar el periodo de siembra y la cosecha proyecta, además de obtener información adicional del tipo de cultivo aprovechando el conocimiento del LLM.

Luego de la experimentación con diferentes arquitecturas LLM, el uso del modelo multimodal *Llama 3.2 11B Vision*, muestran los mejores resultados. Para la construcción del modelo *TSViT-Llama 3.2* se reemplazó el modelo de visión de *Llama 3.2 11B Vision*, por el TSViT, logrando su integración a través de un *Proyector Multimodal* conectado a cada una de los 8 capas *Cross Attention* del modelo LLM de Llama. Para el entrenamiento se consideró como parámetros entrenables tanto el *Proyector Multimodal*, como cada una de las 8 capas *Cross Attention*.

Dado los resultados obtenidos, resulta factible la implementación del modelo multimodal propuesto, de esta forma se propone además, los requerimientos para su operacionalización y consumo, a través de un entorno de producción que se ajuste a los posibles requerimiento de los usuarios en el futuro.

3. Captioning Dataset

3.1. "Humanización" de fechas para descripciones textuales

Para generar mejores descripciones (captions) de los cultivos, a partir de información de siembra y cosecha, se implementó una estrategia de humanización de fechas. En lugar de usar las fechas estrictamente formateadas del dataset original (por ejemplo, 2019-03-15), se tradujeron a expresiones más naturales como *early March 2019*, *mid-April 2019*, o *October 20, 2019*:

- Se definieron tres grupos de patrones para representar tiempos aproximados: **inicio**, **mitad** y **fin** del mes.
- También, se definió un formato de fechas exactas, con día, mes y año: *"March 19, 2019"*.
- En caso de ausencia de fecha, o de la no identificación de periodos siembra-cosecha, se generaron frases como *"by an unknown date"* o *"no planting period was detected for the first planting period of the crop {crop}."* para mantener coherencia gramatical.

Esta humanización permitió utilizar plantillas lingüísticas más naturales, por ejemplo:

Regarding the planting and harvesting times, the crop {crop} was sown around {plant_time} and likely harvested in {harvest_time}."

Estas plantillas fueron rellenas de forma aleatoria y dinámicamente con las fechas humanizadas, generando textos fluidos y fáciles de interpretar.

Este proceso de humanización es crucial para nutrir el dataset de captions que será usado en la etapa de entrenamiento y evaluación de modelos LLM. Al convertir datos crudos a texto fluido y semánticamente significativo, se mejora la calidad del conjunto de datos y se facilita el aprendizaje de relaciones entre componentes espaciales, temporales y semánticos.

Nota: Dado que las muestras del dataset PASTIS fueron obtenidas entre los años 2018 y 2019, se está evaluando la posibilidad omitir las fechas exactas y el año en las fechas generadas (*e.g. mid-March* en lugar de *March 20, 2019* o *early March* en lugar de *early March 2019*). Esto con el fin de reducir el riesgo de sesgo por parte del modelo LLM hacia años y fechas específicas, buscando fomentar que el modelo aprenda patrones estacionales generales, independientemente del año y fecha del calendario.

Ejemplos de descripciones generadas

Ejemplo 1:




Figura 5. Ejemplo 1: Máscara de segmentación.

A cultivated area with Soft winter wheat can be observed with an estimated surface of 24,700 m², Grapevine spanning approximately 9,700 m² which represents a significant portion of the total cultivated land (approximately 57,600 m²).

Now, let's examine the planting and harvesting periods, the crop Soft winter wheat likely experienced its growth period between about the midpoint of October 2018 and on April 15, 2019. Furthermore, the life cycle of Grapevine spanned from on October 12, 2018 to about in the last days of July 2019.




Figura 6. Ejemplo 1: Evolución temporal del cultivo.

Ejemplo 2:




Figura 7. Ejemplo 2: Máscara de segmentación.

The image shows a cultivated area of Meadow. A crop of Meadow can be identified in the image covering about 27,700 m², which covers a notable fraction of the total arable land (approximately 57,600 m²).

Looking into the sowing and reaping periods, the observed agricultural timeline for Meadow suggests planting in the middle of September 2018 and harvesting on July 17, 2019.




Figura 8. Ejemplo 2: Evolución temporal del cultivo.

4. Complejidad en el despliegue y consumo de modelos LLM – Caso LLaMA, Qwen Multimodal y modelos Closed Source

El auge de los modelos de lenguaje de gran escala (LLM) ha revolucionado múltiples áreas del procesamiento de lenguaje natural y la inteligencia artificial aplicada, desde la automatización de procesos hasta la generación de contenido multimodal. Modelos como LLaMA 3.1 y 3.2 desarrollados por Meta, y Qwen Multimodal creado por Alibaba, representan avances significativos en arquitecturas abiertas y flexibles, mientras que los modelos closed source como GPT-4 de OpenAI, Gemini de Google y Claude de Anthropic mantienen un dominio considerable en la industria por su integración completa y soporte técnico Shah2025.

La implementación de estos modelos en entornos empresariales supone un conjunto de decisiones complejas que van más allá de la mera selección tecnológica, implicando consideraciones profundas de arquitectura, inversión, seguridad de datos y cumplimiento normativo Debes2024. Este informe explo-

ra sistemáticamente estas dimensiones de complejidad, ofreciendo un análisis comparativo respaldado por investigación académica reciente y datos técnicos verificados de implementaciones reales.

La relevancia de este análisis radica en la creciente adopción de LLMs en sectores críticos como finanzas, salud y gobierno, donde las decisiones de implementación deben equilibrar la innovación tecnológica con estrictos requisitos regulatorios y de seguridad Allganize2025. La investigación presentada busca proporcionar claridad en un panorama tecnológico en rápida evolución, donde las decisiones de arquitectura tienen implicaciones a largo plazo en costos operativos, flexibilidad y compliance.

5. Consumo por token vs consumo on-premise y escalabilidad

5.1. Modelos Open Source (LLaMA, Qwen Multimodal)

Los modelos de código abierto como LLaMA 3.1/3.2 y Qwen Multimodal presentan arquitecturas de implementación flexibles que permiten tanto consumo vía API como despliegue on-premise, cada enfoque con implicaciones significativas en costos y escalabilidad Bai2023.

El consumo mediante API, frecuentemente ofrecido por proveedores terceros o plataformas de nube híbrida, implementa generalmente un esquema de facturación basado en tokens procesados, diferenciando entre tokens de entrada y salida. Este modelo presenta una estructura de costos variable que escala linealmente con el uso, permitiendo una alta granularidad en la asignación de recursos Shah2025. De acuerdo con análisis recientes, el costo por token para modelos LLaMA 3.1 70B oscila entre \$0.00023 y \$0.00040 por 1000 tokens de entrada y salida respectivamente cuando se consumen a través de proveedores como DeepInfra Shah2025.

En contraposición, el despliegue on-premise ofrece la principal ventaja de poder controlar y predecir costos a largo plazo mediante infraestructura propia, eliminando el pago por token. Esta aproximación requiere una inversión inicial significativa en hardware especializado, particularmente GPUs de alto rendimiento. Según la documentación técnica actualizada, el modelo LLaMA 3.1 de 8B parámetros requiere aproximadamente 18.4 GB de VRAM (reco-

mendado una NVIDIA RTX 4090), mientras que la variante de 70B necesita 161 GB de VRAM, equivalente a dos NVIDIA A100 de 80GB Thor2025.

Para el caso de Qwen-VL, la versión cuantizada (Qwen-VL-Chat-Int4) puede ejecutarse en una GPU con 12GB de memoria, mientras que las versiones completas requieren recursos significativamente mayores para procesamiento multimodal eficiente QwenTeam2025.

La eficiencia del despliegue on-premise está directamente relacionada con la optimización de hardware y software para el modelo específico. Técnicas como la cuantización de parámetros (reduciendo la precisión de 32 bits a 4-8 bits) pueden reducir significativamente los requisitos de memoria - por ejemplo, la versión LLaMA 3 70B-instruct-q2_K requiere solo 26 GB de VRAM (compatible con una NVIDIA RTX 3090) en lugar de los 161 GB de la versión completa Thor2025.

Respecto a la escalabilidad, la investigación empírica demuestra que para operaciones a escala pequeña o media (menos de 8,000 conversaciones diarias), el consumo por token resulta viable y operativamente sencillo Debes2024. Sin embargo, para implementaciones de uso masivo o aplicaciones críticas para el negocio, la transición a modelos on-premise o híbridos se presenta como una estrategia común para reducir costos variables y aumentar el control operativo y de seguridad.

5.2. Modelos Closed Source

Los modelos closed source como GPT-4, Claude y Gemini operan predominantemente bajo modelos de negocio SaaS (Software as a Service) con estructuras de precios por token o por suscripción Shah2025. Estos servicios benefician de infraestructuras altamente optimizadas y escalables, pero ofrecen menor flexibilidad en personalización o control de datos.

El análisis comparativo de costos revela diferencias sustanciales entre proveedores. Los modelos de nivel premium, como las versiones más avanzadas de GPT-4, generalmente presentan costos más elevados tanto para tokens de entrada como de salida en comparación con modelos más básicos Shah2025. Cada proveedor implementa su propia estructura de precios, con tendencia a diferenciar el costo entre tokens de entrada (prompts) y tokens de salida (completions), siendo estos últimos típicamente más costosos.

Según la documentación oficial de OpenAI consultada, existe una clara estratificación de precios entre sus diferentes modelos, con las versiones más avanzadas y especializadas comandando precios considerablemente más al-

tos por millón de tokens procesados OpenAI2025. Similar estratificación se observa en otros proveedores principales del mercado.

Para el caso de servicios cloud como Google y AWS, estos ofrecen diversas opciones con diferentes equilibrios entre capacidades y costos, permitiendo a las organizaciones seleccionar el nivel de servicio que mejor se adapte a sus necesidades y presupuesto Shah2025.

Una característica distintiva de los modelos closed source es que la escalabilidad técnica se gestiona automáticamente por el proveedor, eliminando la necesidad de que el cliente administre infraestructura. Sin embargo, esta conveniencia puede resultar en estructuras de costos menos transparentes y potencialmente más elevadas a gran escala, especialmente para aplicaciones con alto volumen de procesamiento Allganize2025.

6. La interfaz del usuario final vs la complejidad oculta

Para el usuario final, la interacción con sistemas basados en LLMs se presenta usualmente como una interfaz conversacional sencilla e intuitiva. Esta aparente simplicidad oculta una arquitectura subyacente de considerable complejidad técnica y decisiones de implementación con profundas implicaciones operativas, económicas y de seguridad.

La selección del modelo subyacente impacta directamente múltiples dimensiones de la experiencia y operación. La latencia, factor crítico en aplicaciones interactivas, varía significativamente entre modelos: mientras que implementaciones on-premise de LLaMA 3.2 3B pueden ofrecer tiempos de respuesta competitivos en hardware optimizado, modelos más grandes como LLaMA 3.1 70B o implementaciones multimodales como Qwen-VL pueden requerir varios segundos para procesar entradas complejas, especialmente con imágenes de alta resolución Bai2023.

La precisión y capacidades cognitivas también presentan diferencias sustanciales entre modelos. Investigaciones recientes demuestran que modelos de mayor escala como LLaMA 3.1 70B o Claude 3 Opus exhiben capacidades de razonamiento y comprensión contextual significativamente superiores a sus contrapartes más pequeñas, justificando potencialmente mayores costos en aplicaciones que requieren alta precisión o manejo de tareas complejas Kim2023.

En entornos empresariales sofisticados, los proveedores frecuentemente implementan arquitecturas híbridas con estrategias de enrutamiento inteligente (intelligent routing) entre modelos pequeños y grandes para optimizar la relación costo-rendimiento. Esta aproximación permite direccionar consultas simples a modelos eficientes y económicos, reservando modelos más potentes y costosos para tareas que requieren mayor capacidad cognitiva Allganize2025.

El consumo real y las estructuras de costo pueden variar sustancialmente según:

- **Volumen de procesamiento:** Aplicaciones con alta demanda pueden beneficiarse de economías de escala en despliegues on-premise, mientras que usos esporádicos favorecen modelos de consumo por token.
- **Tipo de tarea:** Tareas multimodales, como análisis de imágenes con Qwen Multimodal, requieren recursos computacionales adicionales y suelen implicar mayores costos por operación QwenTeam2025.
- **Arquitectura de implementación:** Configuraciones on-premise, cloud o híbridas presentan diferentes perfiles de costo inicial versus costo operativo continuo Allganize2025.

7. Elección del modelo: factores a considerar

La selección del modelo LLM y su arquitectura de implementación representa una decisión estratégica que debe considerar múltiples factores interrelacionados, más allá del simple rendimiento técnico o costo inmediato.

7.1. Estructura de costos

Las estructuras de costo varían fundamentalmente entre modelos de consumo por token y despliegues con infraestructura propia. El análisis comparativo realizado por Debes2024 demuestra que existe un punto de inflexión en términos de volumen: para organizaciones con menos de 8,000 conversaciones diarias, las soluciones gestionadas por proveedores cloud resultan económicamente más eficientes, mientras que a mayor escala, las soluciones on-premise comienzan a presentar ventajas de costo total de propiedad (TCO).

Los modelos de pago por token presentan una estructura de costos altamente predecible a corto plazo pero potencialmente variable a largo plazo, sujeta a cambios en la política de precios del proveedor. En contraste, las soluciones on-premise requieren una inversión inicial significativa (CAPEX) pero ofrecen costos operativos (OPEX) más estables y predecibles durante la vida útil de la infraestructura Allganize2025.

7.2. Control y privacidad de datos

Las investigaciones en seguridad de LLMs indican que organizaciones con alta sensibilidad de datos, particularmente en sectores como finanzas, salud y gobierno, enfrentan riesgos significativos de exfiltración de información confidencial cuando utilizan APIs de terceros Allganize2025. Esta realidad ha impulsado la preferencia por soluciones on-premise en estos sectores.

La soberanía de datos emerge como consideración primordial: con despliegues on-premise, toda la información permanece dentro del perímetro de seguridad controlado por la organización, simplificando significativamente el cumplimiento de regulaciones como GDPR, HIPAA o requisitos sectoriales específicos Allganize2025.

7.3. Flexibilidad y personalización

Los modelos open source como LLaMA y Qwen permiten niveles de personalización sustancialmente mayores que sus contrapartes closed source. Esto incluye la capacidad de realizar fine-tuning específico para dominios verticales, implementar técnicas de pruning para optimizar rendimiento, o integrar capas adicionales de seguridad y filtrado adaptadas a requisitos organizacionales específicos Xia2023.

Esta flexibilidad resulta particularmente valiosa para organizaciones con casos de uso especializados que se benefician significativamente de adaptaciones al modelo base. Para modelos como LLaMA 3, las versiones cuantizadas (q2_K, q4_K, q6_K) ofrecen diferentes equilibrios entre eficiencia de recursos y precisión, permitiendo seleccionar la configuración óptima según las necesidades específicas y recursos disponibles Thor2025.

7.4. Soporte y mantenimiento

Los modelos closed source ofrecidos como servicio suelen incluir niveles de soporte técnico, actualizaciones automáticas y garantías de disponibilidad (SLAs) que reducen la carga operativa para la organización Allganize2025. En contraste, las implementaciones on-premise de modelos open source requieren equipos técnicos con experiencia específica en LLMOps para mantener la infraestructura optimizada y actualizada.

7.5. Escalabilidad

La facilidad para crecer con la demanda sin incurrir en costos exponenciales representa un factor crítico, particularmente para aplicaciones con patrones de uso variables o crecimiento proyectado. Las soluciones cloud ofrecen escalabilidad inmediata con costos proporcionales, mientras que los despliegues on-premise pueden requerir planificación de capacidad y aprovisionamiento anticipado Allganize2025.

Para modelos on-premise, la escalabilidad también depende de la capacidad de infraestructura: por ejemplo, el despliegue de LLaMA 3.1 405B requeriría aproximadamente 931.5 GB de VRAM (equivalente a 12 GPUs NVIDIA A100 de 80GB), lo que representa un desafío significativo para muchas organizaciones Thor2025.

8. Evolución en costos y recursos computacionales

La trayectoria histórica de los costos computacionales asociados con LLMs muestra una tendencia clara hacia mayor eficiencia y accesibilidad. Según investigaciones recientes, el costo de cómputo para entrenar y desplegar modelos de lenguaje de gran escala ha disminuido considerablemente gracias a avances paralelos en hardware especializado y técnicas de optimización de software Xia2023.

En el ámbito hardware, la evolución de GPUs especializadas para IA como las series NVIDIA A100 y H100, así como aceleradores alternativos como TPUs de Google, ha permitido incrementos significativos en eficiencia computacional por vatio y por dólar invertido. Paralelamente, innovaciones

arquitectónicas en diseño de chips especializados están reduciendo la barrera económica para inferencia de LLMs Meta2024.

En el dominio de optimización de software, técnicas como la cuantización de parámetros, el pruning selectivo de conexiones neuronales, y la destilación de conocimiento están permitiendo implementar versiones más eficientes de modelos complejos sin sacrificar significativamente su rendimiento Xia2023. El estudio de Zhang2024 sobre TinyLlama demuestra que es posible crear modelos compactos de 1.1B de parámetros con rendimiento comparable a modelos significativamente más grandes en tareas específicas.

Esta evolución tecnológica ha democratizado el acceso a LLMs, abriendo la posibilidad a más organizaciones para implementar despliegues on-premise o modelos personalizados sin necesidad de infraestructuras descomunales. Por ejemplo, LLaMA 3.2 1B-instruct-q2_K requiere apenas 581 MB de VRAM, siendo compatible incluso con GPUs de gama media-baja como la NVIDIA GTX 1050 Ti Thor2025.

Sin embargo, la demanda creciente de capacidades multimodales y contextos más extensos continúa impulsando innovaciones y ajustes en costos operativos. Modelos como Qwen-VL que integran capacidades de procesamiento visual requieren recursos adicionales específicos para la componente de visión, aumentando la complejidad de optimización y los requisitos de hardware QwenTeam2025.

9. Riesgo y compliance en industrias reguladas

Las industrias altamente reguladas como la financiera, sanitaria y gubernamental enfrentan un conjunto particularmente desafiante de consideraciones al implementar tecnologías LLM. Estas organizaciones operan bajo estrictos marcos regulatorios que imponen controles específicos para el manejo de datos confidenciales, limitando significativamente las opciones de implementación tecnológica Azubuike2024.

Investigaciones recientes sobre gestión de riesgos estratégicos en instituciones financieras demuestran que el cumplimiento normativo en el contexto de implementaciones de IA generativa requiere un enfoque integral que abarca desde la arquitectura tecnológica hasta los procesos de gobernanza y auditoría Adeniran2024. Este cumplimiento obliga a evaluar rigurosamente

múltiples dimensiones críticas:

La ubicación del procesamiento de datos emerge como consideración primordial. Regulaciones como GDPR en Europa, HIPAA en EE.UU. para datos sanitarios, o normativas financieras como PCI-DSS imponen restricciones específicas sobre dónde pueden procesarse ciertos tipos de datos sensibles. Esto frecuentemente limita o impide completamente el uso de servicios en la nube pública o modelos alojados fuera del perímetro de seguridad corporativo Allganize2025.

El control de acceso a los modelos y resultados representa otra dimensión crítica. Las organizaciones reguladas deben mantener estrictos controles sobre quién puede interactuar con sistemas de IA y qué nivel de información pueden extraer, requiriendo capacidades avanzadas de autenticación, autorización y registro de actividad Adeniran2024.

La auditoría y trazabilidad de uso constituyen requisitos fundamentales. Las regulaciones financieras y sanitarias típicamente exigen mantener registros detallados de todas las interacciones con sistemas automatizados, permitiendo reconstruir exactamente cómo se generaron recomendaciones o decisiones Bagwe2024. Esta necesidad puede resultar particularmente desafiante con modelos closed source donde la visibilidad interna del procesamiento es limitada.

Estas exigencias regulatorias han conducido a que ciertos sectores adopten predominantemente arquitecturas on-premise para sus implementaciones de LLM, privilegiando el control y la seguridad sobre la conveniencia operativa. La investigación de Allganize2025 destaca que la seguridad es un factor decisivo clave para empresas donde la protección de datos e IP es de importancia estratégica, influyendo significativamente en la preferencia por soluciones on-premise a pesar de los mayores costos iniciales y complejidad operativa asociados.

Esta realidad regulatoria hace que para ciertos sectores la adopción completa de modelos LLM sea un proceso más lento y metódico, caracterizado por extensas evaluaciones de riesgo, pruebas controladas y despliegues graduales bajo estricta supervisión Azubuike2024.

10. Conclusión

El análisis formal presentado en este documento demuestra que desplegar y consumir modelos de lenguaje de gran escala (LLM) involucra una serie de

complejidades técnicas, financieras y regulatorias que deben ser comprendidas exhaustivamente para fundamentar decisiones estratégicas de implementación.

La evolución tecnológica tanto en hardware especializado como en técnicas de optimización de software ha transformado significativamente el panorama de accesibilidad a estas tecnologías, habilitando opciones de implementación que eran prohibitivamente costosas hace apenas algunos años Thor2025. Esta democratización del acceso a LLMs está ampliando el espectro de organizaciones que pueden beneficiarse de capacidades avanzadas de procesamiento de lenguaje natural.

Sin embargo, el riesgo y cumplimiento normativo continúan siendo factores determinantes, particularmente para sectores sensibles como el financiero, sanitario y gubernamental. Las estrictas exigencias regulatorias en estos ámbitos frecuentemente dictaminan arquitecturas de implementación específicas, priorizando el control y la seguridad sobre consideraciones de costo o conveniencia operativa Adeniran2024.

La decisión entre modelos open source como LLaMA y Qwen versus alternativas closed source, así como la elección entre consumo por token o infraestructuras propias, requiere un análisis multidimensional que equilibre factores de costo, control, escalabilidad y seguridad. Este balance debe alinearse estratégicamente con las necesidades específicas, contexto regulatorio y proyecciones de crecimiento de cada organización.

En última instancia, la implementación exitosa de LLMs en contextos empresariales exige un enfoque holístico que trascienda consideraciones puramente técnicas para abarcar aspectos de gobernanza, gestión de riesgos y alineación estratégica con objetivos organizacionales.

Tabla 1. Comparativa entre modelos LLaMA, Qwen y proveedores cloud
(Parte 1)

Característica	LLaMA 3.1 / 3.2	Qwen Multi-modal	Google Cloud	Amazon AWS
Tipo de modelo	Código abierto (LLM)	Código abierto (Multimodal LLM)	Closed Source SaaS LLM	Closed Source SaaS LLM
Tamaño modelo	7B a 405B parámetros	7B a 14B parámetros (multimodal + texto)	Varía, típicamente 20B+ parámetros	Varía, Titan ~13B parámetros
Consumo GPU aproximado	LLaMA 3.1 8B: 18.4 GB VRAM (RTX 4090) LLaMA 3.1 70B: 161 GB VRAM (2x A100 80GB) LLaMA 3.2 1B: 2.3 GB VRAM Versiones cuantizadas: Hasta 85 % menos VRAM	Qwen-VL-Chat-Int4: 12 GB VRAM Qwen-VL: Mayor requerimiento para procesamiento de imágenes	No aplica (servicio gestionado)	No aplica (servicio gestionado)
Costo aprox. (on-premise)	GPU ~2-5 USD/hora por GPU A100	Similar a LLaMA pero más alto por multimodal	N/A (cobran por uso API)	N/A (cobran por uso API)
Costo por token (API)	Depende del proveedor, si se usa Hugging Face o similar, puede ser \$0.0001 - \$0.0004 por 1k tokens	Similar o ligeramente mayor por multimodal	Variable según modelo, generalmente estructura de costos diferenciada para tokens de entrada y salida	AWS Titan: ~\$0.00075 - 0.001 por 1k tokens

Tabla 2. Comparativa entre modelos LLaMA, Qwen y proveedores cloud (Parte 2)

Característica	LLaMA 3.1 / 3.2	Qwen Multi-modal	Google Cloud	Amazon AWS
Escalabilidad	Depende de infraestructura propia; requiere gestión	Igual, con complejidad extra para multimodal	Alta, sin infraestructura propia	Alta, sin infraestructura propia
Flexibilidad / Personalización	Alta, código abierto para ajustes y fine-tuning	Alta, pero mayor complejidad por datos multimodales	Limitada a configuraciones y prompt design	Limitada a configuraciones y prompt design
Privacidad y Compliance	Total control si on-premise	Igual que LLaMA	Datos procesados en nube pública	Datos procesados en nube pública
Latencia típica	Baja si está en infraestructura local	Similar, puede ser más alta para multimodal	Variable, depende del tráfico y red	Variable, depende del tráfico y red

Nota: Los costos y consumos GPU son aproximados y pueden variar según optimizaciones, versión del modelo y uso. Precios actualizados a junio de 2025.

Fuentes: Thor2025, QwenTeam2025, OpenAI2025, Shah2025

Referencias

[Adeniran et al.(2024)] Adeniran, I. A., Abhulimen, A. O., Obiki-Osafiele, A. N., Osundare, O. S., Agu, E. E., & Efunniyi, C. P. (2024). Strategic risk management in financial institutions: Ensuring robust regulatory compliance. *Finance & Accounting Research Journal*, 6(8).

[Allganize(2025)] Allganize. (2025). How to Choose the Best Deployment Model for Enterprise AI: Cloud vs On-Prem. *Allganize AI Resources*.

[Azubuike(2024)] Azubuike, J. I. (2024). The Role of Predictive Analytics in Automating Risk Management and Regulatory Compliance in the U.S. Financial Sector. *European Journal of Accounting, Auditing and Finance Research*, 12(1), 19-31.

- [Bagwe(2024)] Bagwe, C. (2024). Streamlining Compliance And Risk Management with Regtech Solutions. *International Journal of Computer Science & Information Technology*, 16(3).
- [Bai et al.(2023)] Bai, J., Bai, S., Yang, S., Wang, S., Tan, S., Wang, P., Lin, J., Zhou, C., & Zhou, J. (2023). Qwen-VL: A Frontier Large Vision-Language Model with Versatile Abilities. *arXiv preprint*.
- [Debes(2024)] Debes, H. (2024). Cost Analysis of deploying LLMs: A comparative Study between Cloud Managed, Self-Hosted and 3rd Party LLMs. *Artefact Engineering and Data Science*.
- [Kim et al.(2023)] Kim, W., Spörer, J., Lee, C. L., & Handschuh, S. (2023). Is Small Really Beautiful for Central Bank Communication? Evaluating Language Models for Finance: Llama-3-70B, GPT-4, FinBERT-FOMC, FinBERT, and VADER. *International Conference on AI in Finance*.
- [Meta(2024)] Meta. (2024). Presentamos Meta Llama 3: modelo de lenguaje a gran escala más potente hasta la fecha. *Meta AI Research*.
- [OpenAI(2025)] OpenAI. (2025). API Pricing. *OpenAI Documentation*. <https://openai.com/api/pricing/>
- [Qwen Team(2025)] Qwen Team. (2025). Qwen-VL: Qwen Large Vision Language Model. *GitHub Repository*. <https://github.com/QwenLM/Qwen-VL>
- [Shah(2025)] Shah, A. (2025). Navigating the LLM Cost Maze: A Q2 2025 Pricing and Limits Analysis. *Medium*.
- [Thor(2025)] Thor, W. M. (2025, May 25). GPU Requirement Guide for Llama 3 (All Variants). *ApX Machine Learning*. <https://apxml.com/posts/ultimate-system-requirements-llama-3-models>
- [Xia et al.(2023)] Xia, M., Gao, T., Zeng, Z., & Chen, D. (2023). Sheared LLaMA: Accelerating Language Model Pre-training via Structured Pruning. *International Conference on Learning Representations*.
- [Zhang et al.(2024)] Zhang, P., Zeng, G., Wang, T., & Lu, W. (2024). TinyLlama: An Open-Source Small Language Model. *arXiv preprint*.

Anexos

El código fuente, incluyendo notebooks y scripts, se encuentran disponibles en el siguiente repositorio de GitHub:

- **Repositorio:** `github.com/juanrtato/crop-image-deepanalysis`
- **Captions dataset testing:** `notebooks/captions_dataset.ipynb`
- **Util scripts and functions:** `scripts/utils.py`